BDA, Praktikumsbericht 2

Gruppe mi6xc: Alexander Kniesz, Maximilian Neudert, Oskar Rudolf

Aufgabe 1

a)

Zuerst sollen wir ein Clustering auf der 10k-Stichprobe machen. Die KMeans Methode von `pyspark.ml` erwartet dazu ein DataFrame mit genau einer Spalte oder ein DataFrame mit einer Spalte `features`. Um dies zu ermöglichen transformieren wir die `bin_x` Spalten mit einem `VectorAssembler` zu einer feature Spalte, in der die vorherhigen Spalten die Dimensionen der neuen Vektoren sind. Dabei ist zu beachten, dass `VectorAssembler` je nach Speicherauslastung automatisch sparse oder voll wählt und in unserem Fall werden es sparse Vectoren, Das heißt, dass wir sehr viele 0 Werte haben. Anschließend erstellen wir ein KMeans object `KMeans().setK(2).setSeed(1)` durch Angabe der gewünschten Clusteranzahl (k=2) und des Start-Seeds und fitten damit dann das Modell anhand des neuen DataFrames.

FINISHED

```
%pyspark
# aufgabe 1
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.clustering import KMeans
from pyspark.ml.clustering import KMeansModel
from pyspark.ml.evaluation import ClusteringEvaluator

df = spark.sql("SELECT * FROM mi6xc_profilevectors")

assy = VectorAssembler(
    inputCols=["bin_0", "bin_1", "bin_2", "bin_3", "bin_4", "bin_5", "bin_6", "bin_7", "bin_8"],
    outputCol="features")

df_vec = assy.transform(df).select("features")

df_vec.show(5)

kmeans = KMeans().setK(2).setSeed(1)
model = kmeans.fit(df_vec)
```

```
+--------------------+
|            features|
+--------------------+
|[0.0,0.0,0.01,0.0...|
|(9,[4,5,6,7],[0.0...|
|(9,[5,6,7],[0.02,...|
|[0.0,0.01,0.02,0....|
|(9,[4,5,6,7],[0.0...|
+--------------------+
only showing top 5 rows
```

b)

Als quadratischen Fehler erhalten wir für die Wahl an Centroiden:

```
%pyspark
# Evaluate clustering.
cost = model.computeCost(df_vec)

# Quadratischer Fehler
print(cost)
```

```
1175.5134576277374
```

c)

Plotten wir die quadratischen Fehler im Bereich 2 bis 16 (Anzahl an Centroiden), so erhalten wir folgenden Plot:

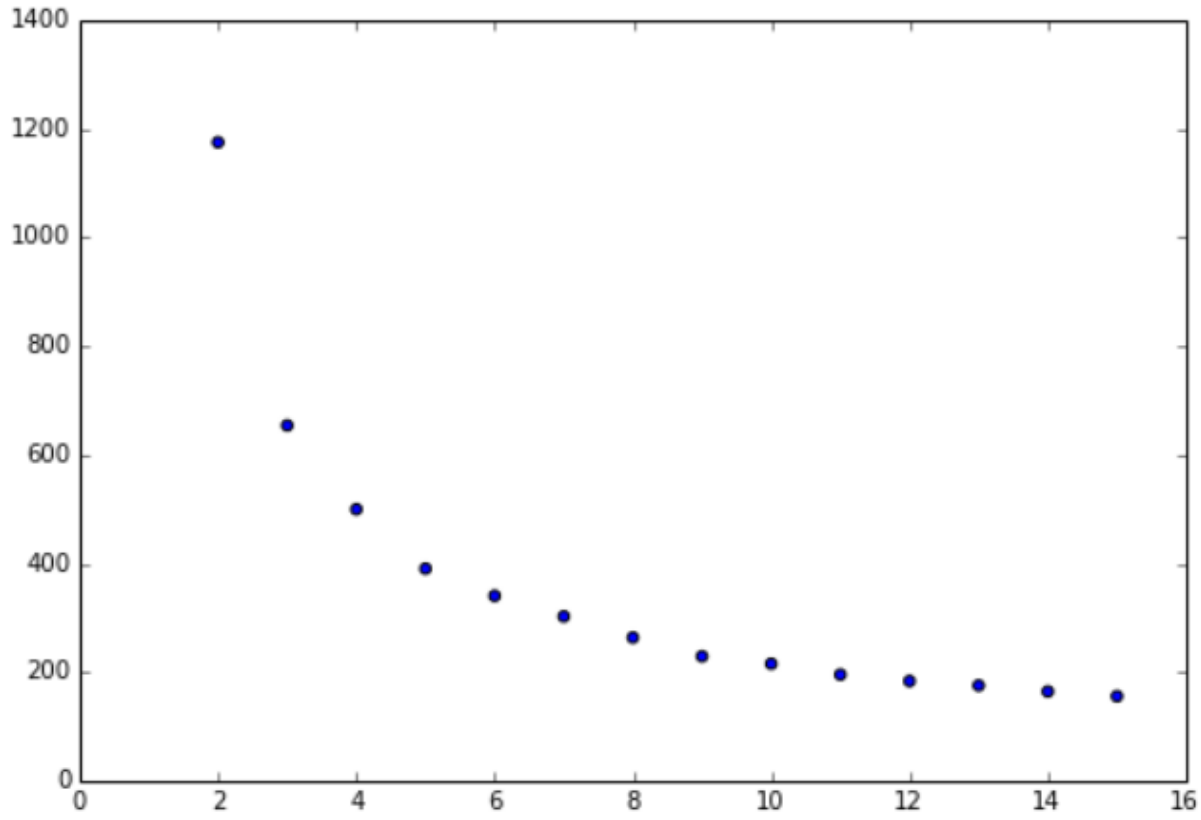

Bei dem dabei entstandenen Plot wenden wir die Elbow-Methode an, bei dir wir abschätzen, ab welcher Anzahl von Clustern sich die Steigung kaum noch ändert. Wir entscheiden uns für **5** Cluster, da der Unterschied von 4 zu 5 nach unserer Meinung noch nennenswert ist, zusätzliche Cluster ab diesem Punkt aber kaum noch Mehrwert bringen:

FINISHED

```
%pyspark

kmeans_final = KMeans().setK(5).setSeed(1)
model_final = kmeans_final.fit(df_vec)

centers = model_final.clusterCenters()

print("Cluster Centers: ")
for center in centers:
    print(center)

# quadratischer Fehler
cost = model_final.computeCost(df_vec)
print("Error: " + str(cost))

# Save model
model_final.write().overwrite().save("hdfs://141.100.62.85:9000/user/istosrudo/gruppe_mi6x_k_means_5_model")
```

```
Cluster Centers:
[1.26396425e-03 2.11937440e-03 4.82604532e-03 1.24130227e-02
 3.98691350e-02 2.04101500e-01 6.33562081e-01 9.91318225e-02
 9.57548675e-06]
[3.90025575e-04 7.03324808e-04 1.68797954e-03 4.11125320e-03
 9.92966752e-03 2.75255754e-02 1.59283887e-01 7.75147059e-01
 1.74552430e-02]
[8.98804048e-03 3.05059798e-02 9.27046918e-02 2.37442502e-01
 3.75722171e-01 2.09337626e-01 4.00459982e-02 3.69825207e-03
 2.75988960e-05]
[1.71490281e-03 3.62850972e-03 1.05874730e-02 3.91317495e-02
 1.71943844e-01 4.92496760e-01 2.62574514e-01 1.55507559e-02
 7.77537797e-05]
[0.00091005 0.0016728  0.00395581 0.01051026 0.02789058 0.09693319
 0.42960021 0.42037875 0.00516044]
Error: 390.7951234005651
```

d)

Anwendung unseres Cut-Off-Kriteriums k=5 auf den k-means-Algorithmus und abspeichern des resultierenden Modells:

```
%pyspark

kmeans_final = KMeans().setK(5).setSeed(1)
model_final = kmeans_final.fit(df_vec)

centers = model_final.clusterCenters()

# quadratischer Fehler
cost = model_final.computeCost(df_vec)
print("Error: " + str(cost))

# Save model
model_final.write().overwrite().save("hdfs://141.100.62.85:9000/user/istosrudo/gruppe_mi6x_k_means_5_model")
```

```
Error: 390.7951234005651
```

Took 4 sec. Last updated by istosrudo at May 14 2019, 3:30:08 PM.

e) - f)

Um mit den Daten in Tableau arbeiten zu können erstellen wir eine neue Tabelle mit den Profilvektoren einerseits und den aus dem Modell berechneten Predictions andererseits. Die so erstellte Tabelle zeigt uns nun für jeden Track eine zugehörige Clusternummer:

```
%pyspark
from pyspark.sql.functions import concat, col, lit
from pyspark.sql.functions import monotonically_increasing_id
import numpy as np

predictions = model_final.transform(df_vec).select("prediction")


left = df.withColumn("index",monotonically_increasing_id())
right = predictions.withColumn("index",monotonically_increasing_id())

result_df = left.join(right, on="index")
result_df.write.mode("overwrite").saveAsTable("mi6xc_k_means_10k")

result.show()
```

index	track_id	bin_0	bin_1	bin_2	bin_3	bin_4	bin_5	bin_6	bin_7	bin_8	prediction
0	TRAZKDD12903CC8328	0.0	0.0	0.01	0.01	0.07	0.21	0.51	0.19	0.0	0
1	TRALYIQ12903CEC83A	0.0	0.0	0.0	0.0	0.03	0.32	0.6	0.04	0.0	0
2	TRADTBA128F92CA48F	0.0	0.0	0.0	0.0	0.0	0.02	0.22	0.76	0.0	1
3	TRAEDJW128F422B4CB	0.0	0.01	0.02	0.07	0.24	0.56	0.11	0.0	0.0	3
4	TRATPUS128F4271260	0.0	0.0	0.0	0.0	0.03	0.29	0.65	0.02	0.0	0
5	TRABIOI12903CD8B9B	0.0	0.0	0.0	0.0	0.01	0.02	0.12	0.84	0.0	1
6	TRAZUKY128F426C8BC	0.0	0.0	0.01	0.0	0.01	0.03	0.15	0.8	0.0	1
7	TRBHBEB128F92CC0C6	0.0	0.0	0.0	0.01	0.15	0.54	0.29	0.0	0.0	3
8	TRASOQC12903CFFED7	0.0	0.0	0.0	0.0	0.0	0.01	0.04	0.94	0.0	1
9	TRAVHPV128F933E986	0.0	0.0	0.0	0.01	0.01	0.06	0.39	0.53	0.0	4
10	TRALNOD128F4264AEB	0.0	0.0	0.0	0.01	0.04	0.38	0.56	0.0	0.0	0
11	TRAOVFR128F93275B4	0.01	0.0	0.02	0.04	0.16	0.32	0.42	0.03	0.0	3
12	TRAXDLB128F423F8F8	0.0	0.0	0.01	0.0	0.01	0.12	0.76	0.09	0.0	0
13	TRAJLOY128F92E4EAF	0.01	0.01	0.01	0.02	0.16	0.41	0.13	0.23	0.0	3
14	TRAPOOP128F42142F6	0.0	0.02	0.16	0.38	0.14	0.18	0.12	0.0	0.0	2

Anschließend haben wir die Tabelle mit den restlichen Daten in Tableau verbunden verbunden:

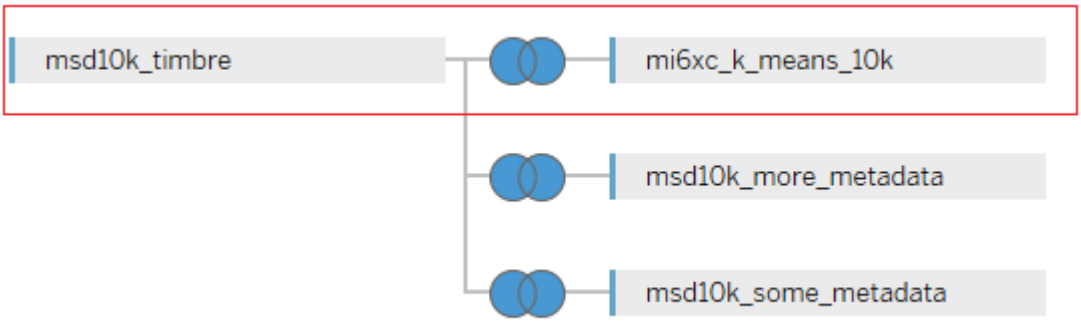

g)

Bevor wir zur Visualisierung in Tableau übergehen, haben wir zunächst noch in Python ein anschauliches Modell zur Vergleich der Cluster-Laustärkeprofile geplottet. Dieses berechnet sich aus der gewichteten Summe über die Bins:

FINISHED

```
%pyspark
from matplotlib import pyplot as plt

for c, center in enumerate(centers):
    k = 0
    for i in range(0, len(center)):
        k += i * center[i]

    # plot models
    plt.plot(range(0, len(center)) , center, 'o-', label='center {}, weight sum: {}'.format(c, round(k, 2)))
    plt.legend(loc='upper left')

plt.show()
```

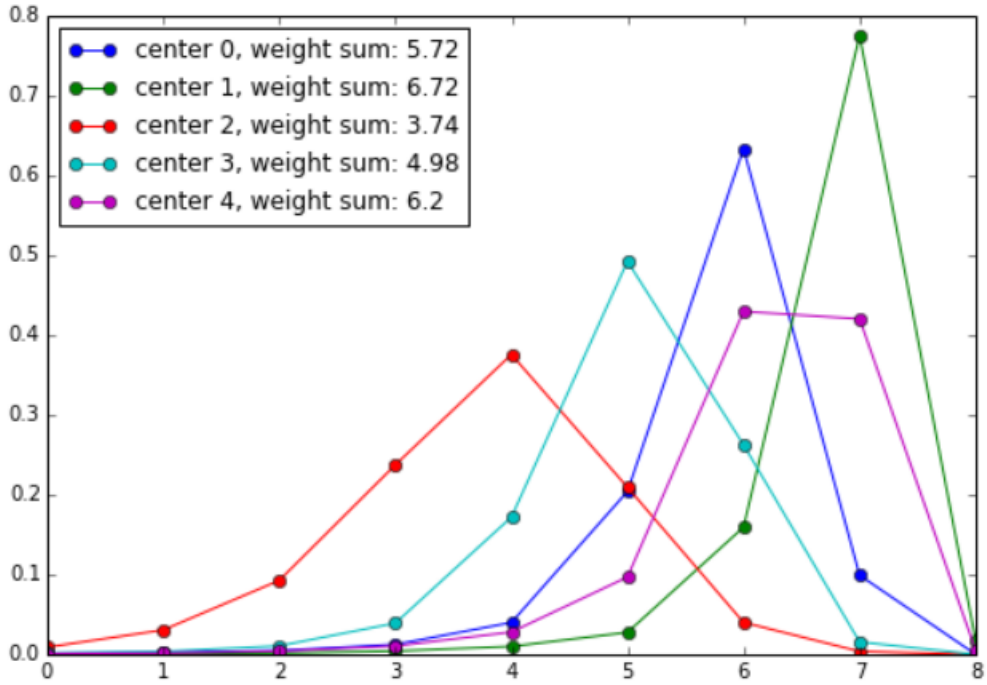

Der resultierende Plot gibt uns eine Auskunft über die Laustärkeprofile, die unsere Cluster repräsentieren.

Tableau

Plot 1

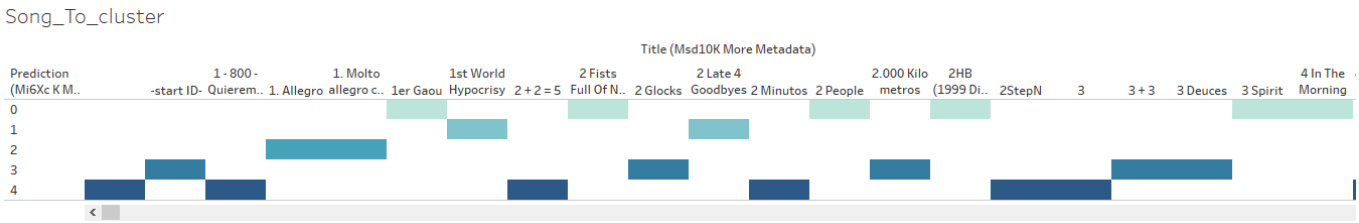

Plot 1 dient einer einfachen Übersicht der Songs und deren Zuordnung zu den Clustern. Streng genommen wäre eine zusätzliche Farbkodierung der Cluster nicht notwendig gewesen, allerdings viel uns auf, dass die Unterscheidung auf den ersten Blick mit unterschiedlichen Farbstufen um einiges schneller geht, als die Unterscheidung zwischen Schwarzen Balken.

Plot 2

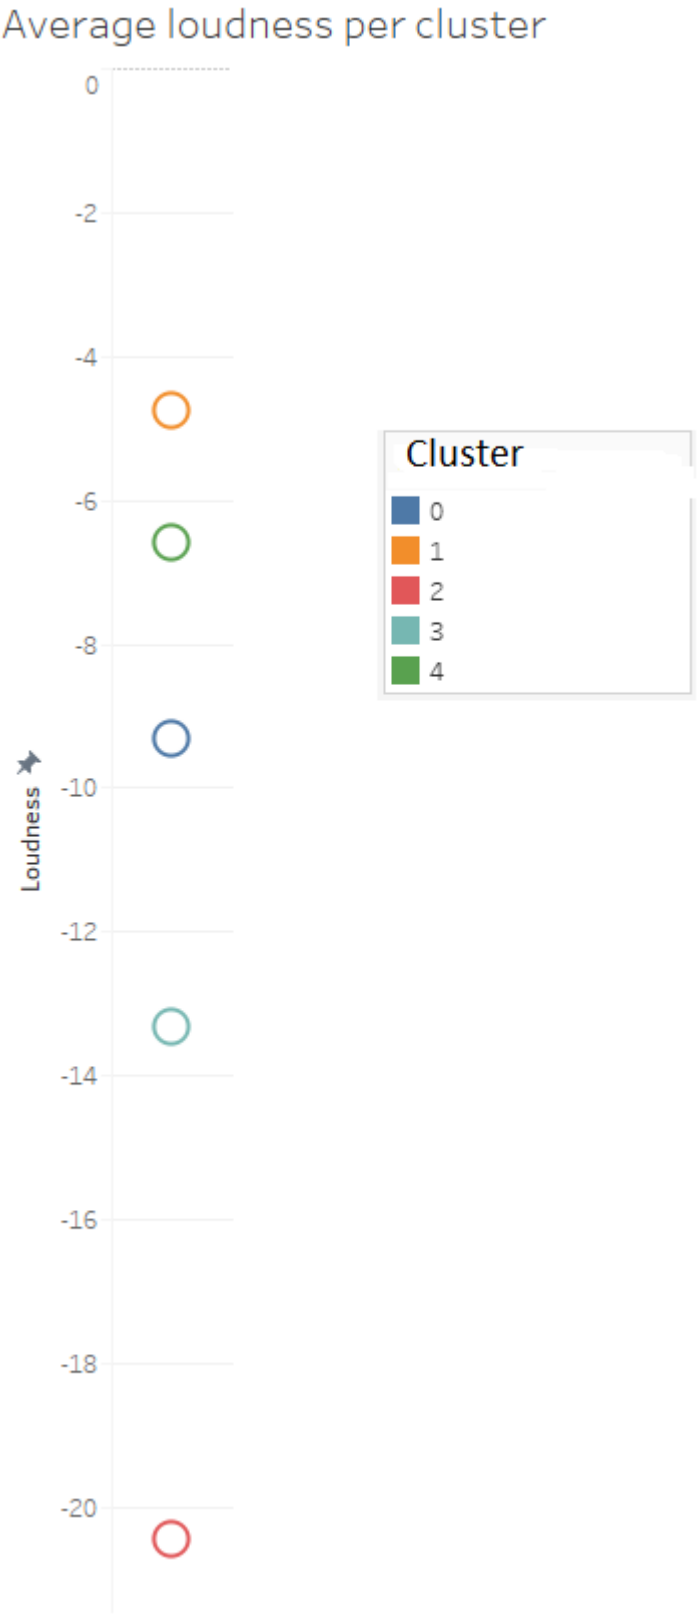

Da es sich bei den Timbre_0 um die Laustärke der Segmente handelt, drängte sich gleich die Frage auf, wie sich die Cluster bezüglich der durchschnittlichen Lautstärke aus den Metadaten entschieden. Auskunft darüber gibt uns Plot 2.

Plot 3

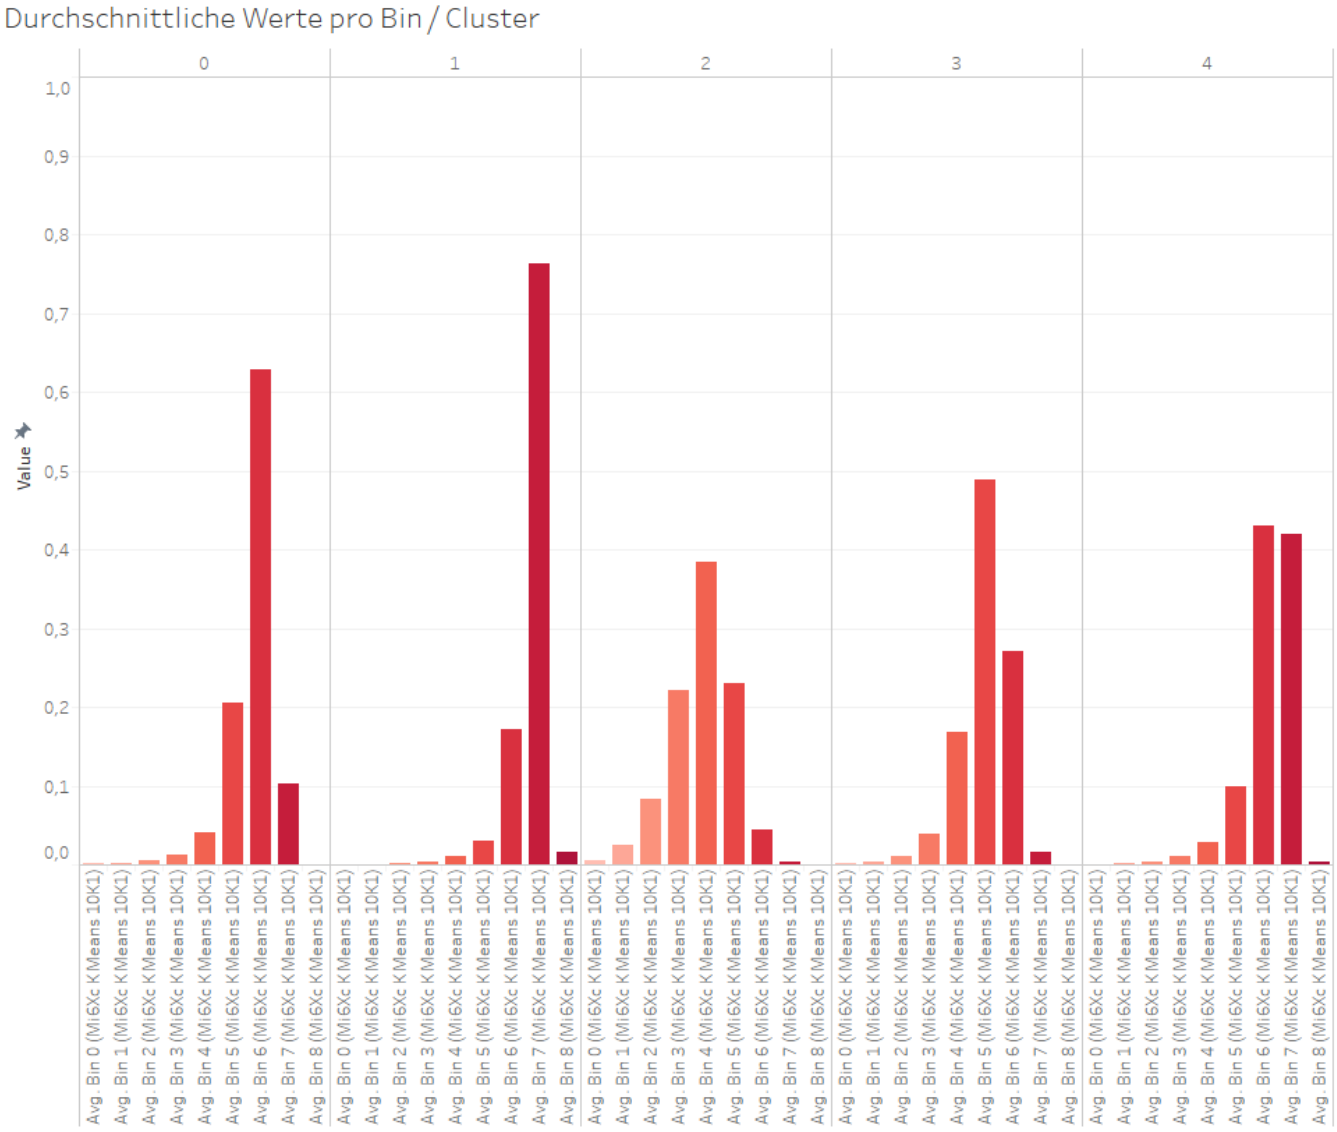

In Plot 3 sehen wir, wie in der Aufgabe vorgeschlagen, die durchschnittlichen Bins pro Cluster. Auffällig ist, dass Cluster Nr. 1 die meisten lauten Segmente zu haben scheint, d.h. dessen Verteilung am Stärksten nach rechts verschoben ist.

Plot 4

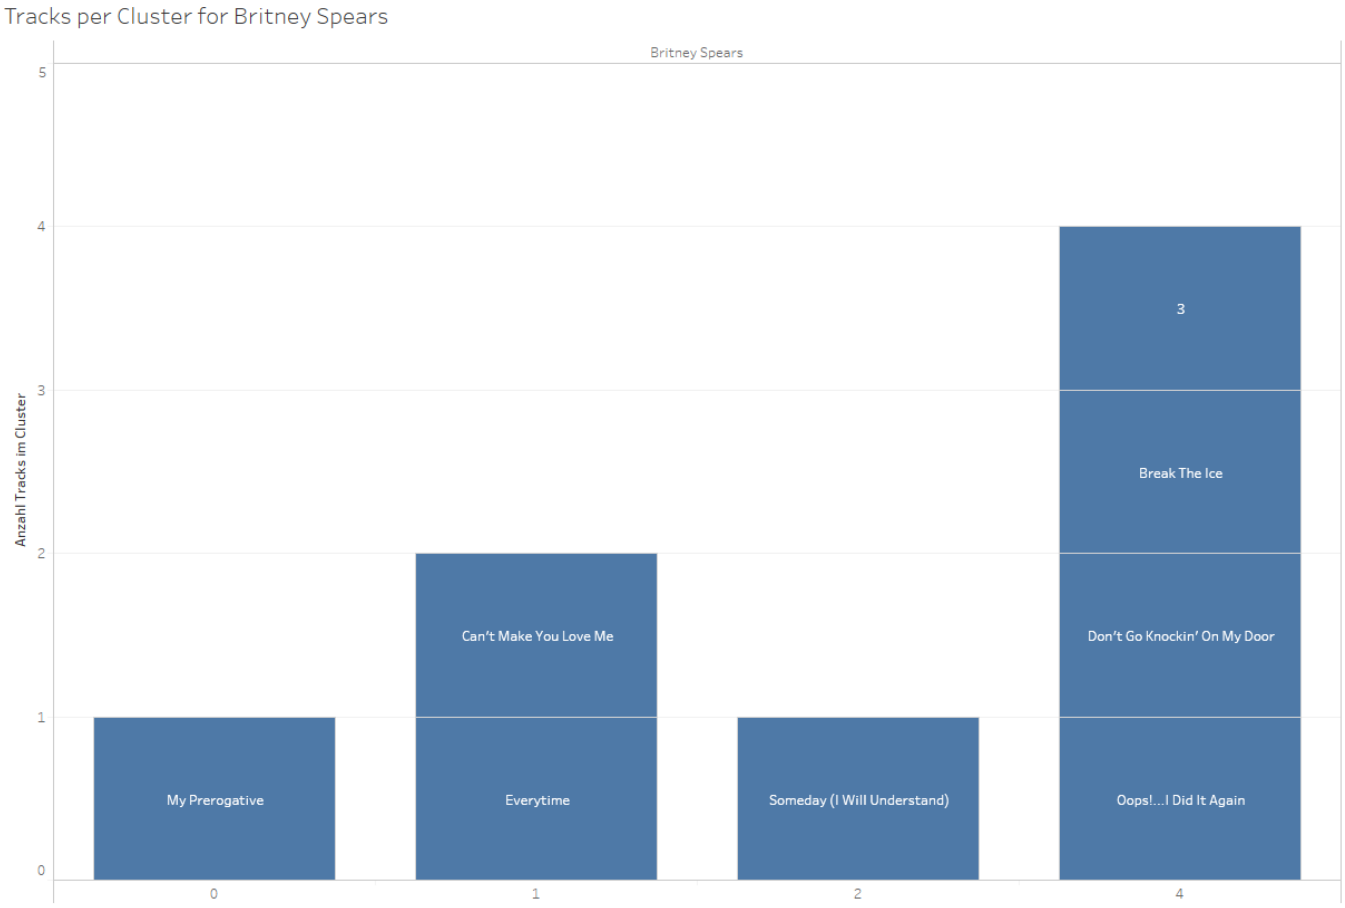

Nach langer Diskussion darüber, welche/r Künstler/in ausgesucht wird, präsentieren wir nun in Plot 4 die in Cluster aufgeteilten Songs der US-amerikanischen PopSängern "Britney Spears" (*2. Dezember 1981 in McComb, Mississippi)). In den Balken sind die Songtitel zu sehen (Soundproben unter Aufgabe h))

Plot 5

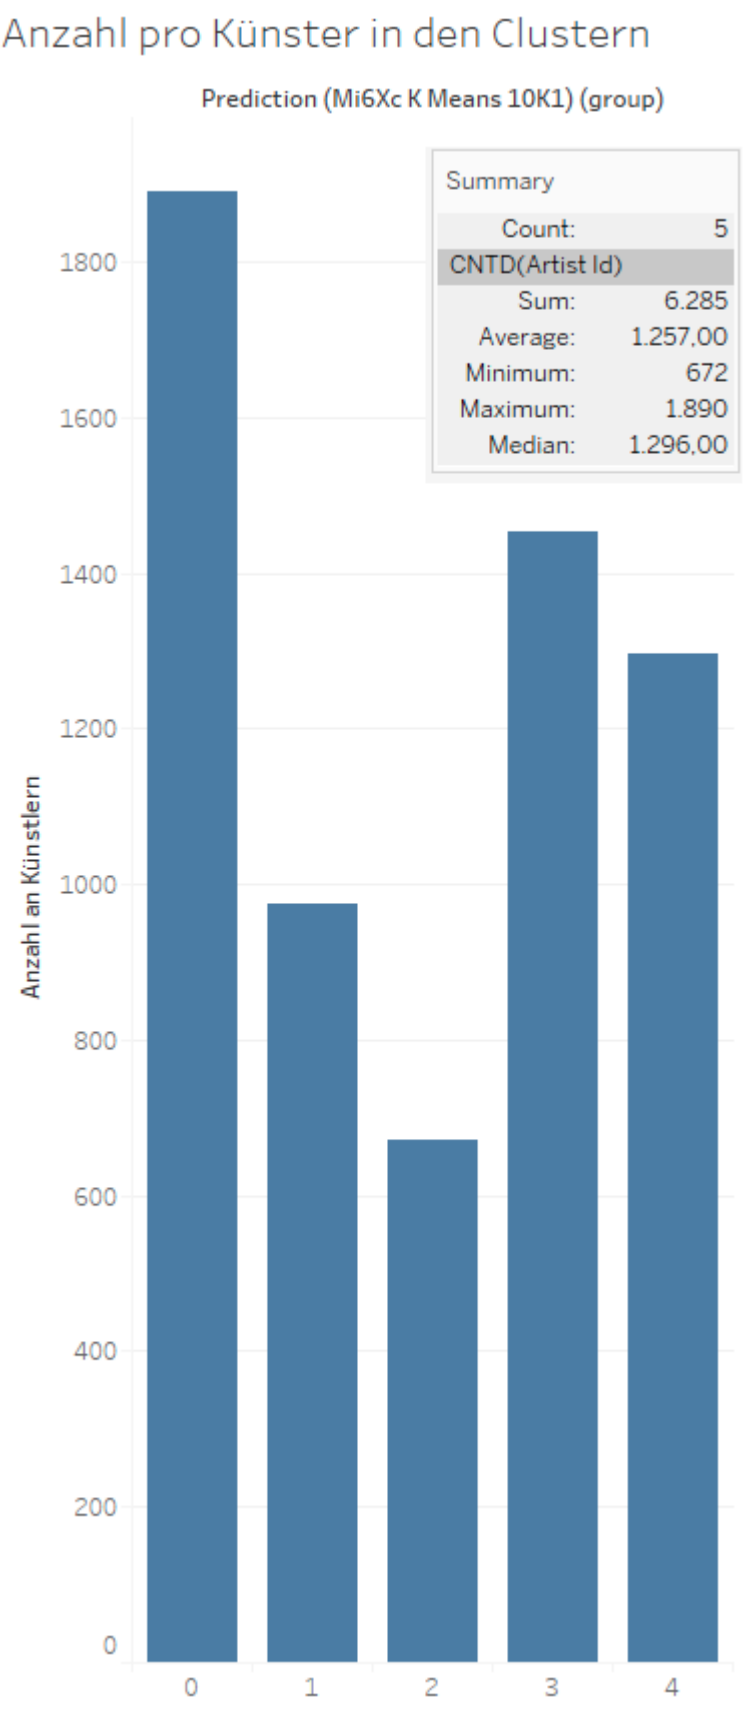
Anzahl pro Künster in den Clustern
Prediction (Mi6Xc K Means 10K1) (group)
Summary
Count: 5
CNTD(Artist Id)
Sum: 6.285
Average: 1.257,00
Minimum: 672
Maximum: 1.890
Median: 1.296,00
Anzahl an Künstlern
1800
1600
1400
1200
1000
800
600
400
200
0
0
1
2
3
4

Plot 6

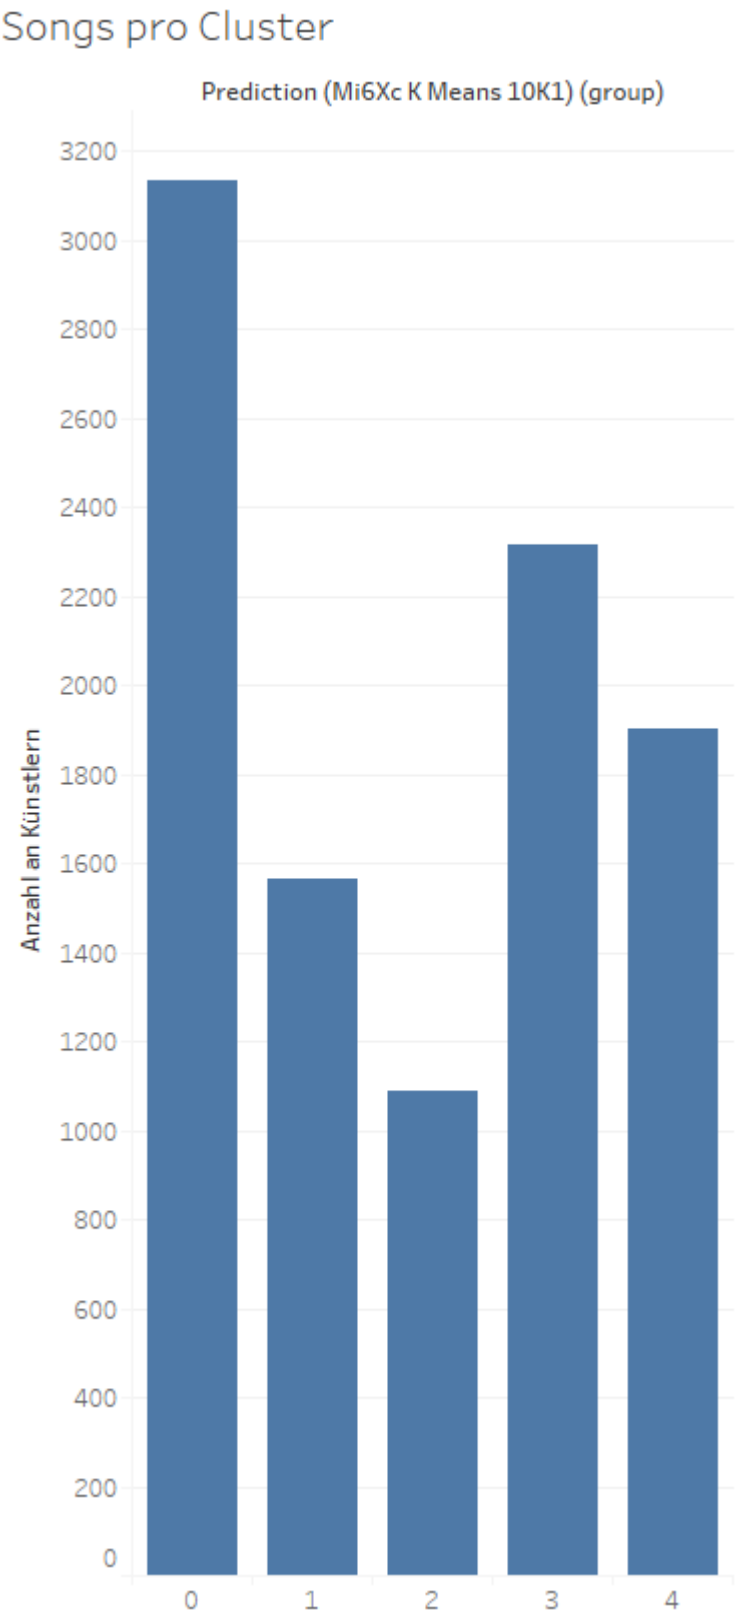

Plots 5 & 6 zeigen einfach, wie viele Künstler bzw. Titel im Cluster vertreten sind. Zum Vergleich: Insgesamt gibt es 3380 Künstler und 10000 Songtitel.

Plot 7

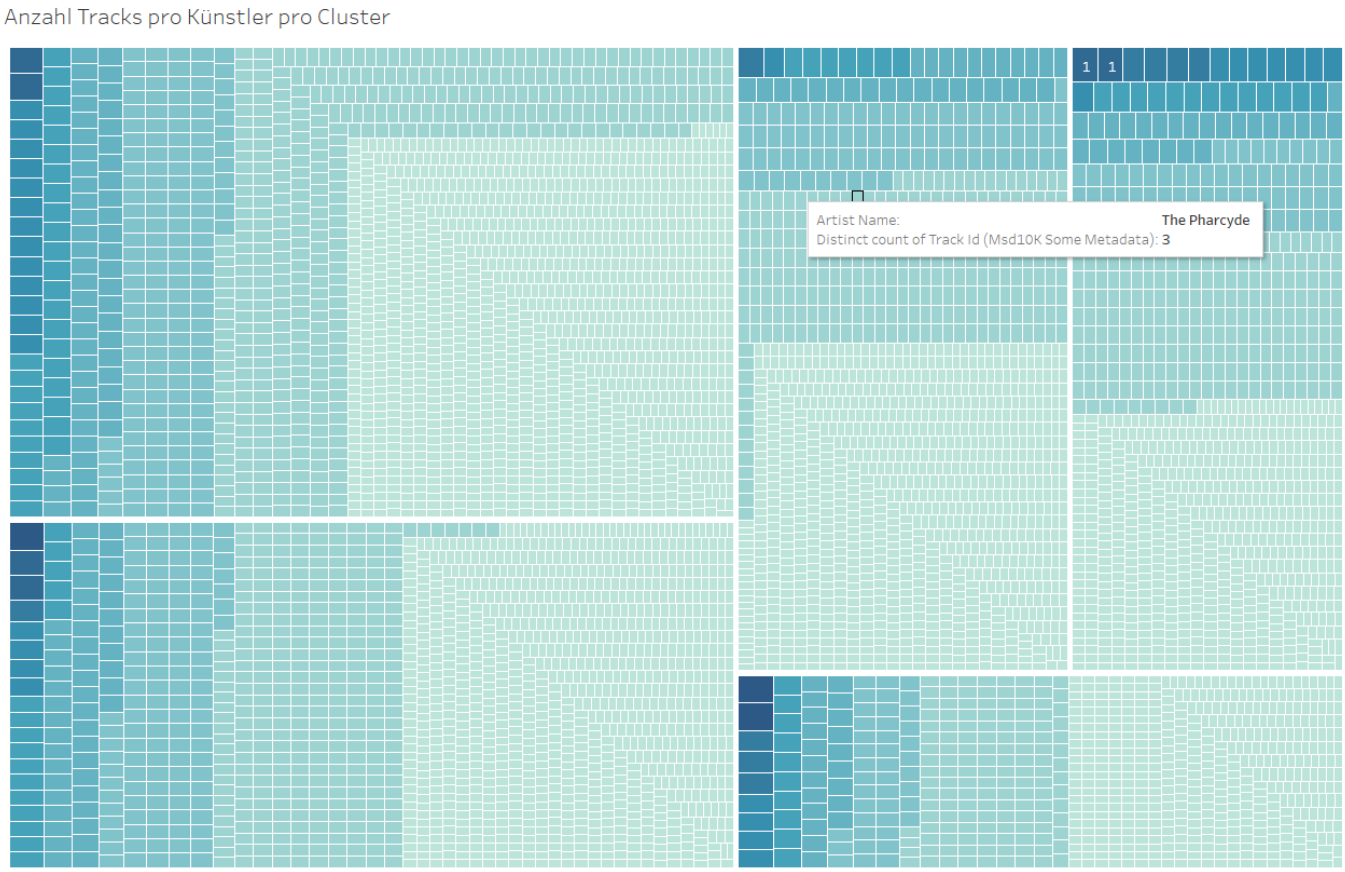

Im 7. Plot ist die Information aus 5 & 6 in einer einzigen Grafik zusammengefasst. Die "großen" 5 Mosaiksteine entsprechen den fünf Clustern. Jedes kleinere Mosaik entspricht einem Künstler und die Größe bzw. Farbe dieses Rechtecks sagt aus, wie viele Songs dieses Künstlers in diesem Cluster auftauchen. Auch hier hilft die zusätzliche Farbkodierung auf ein schon dargestelltes Merkmal **deutlich** bei der Unterscheidung der einzelnen Bestandteile der Grafik.

Plot 8

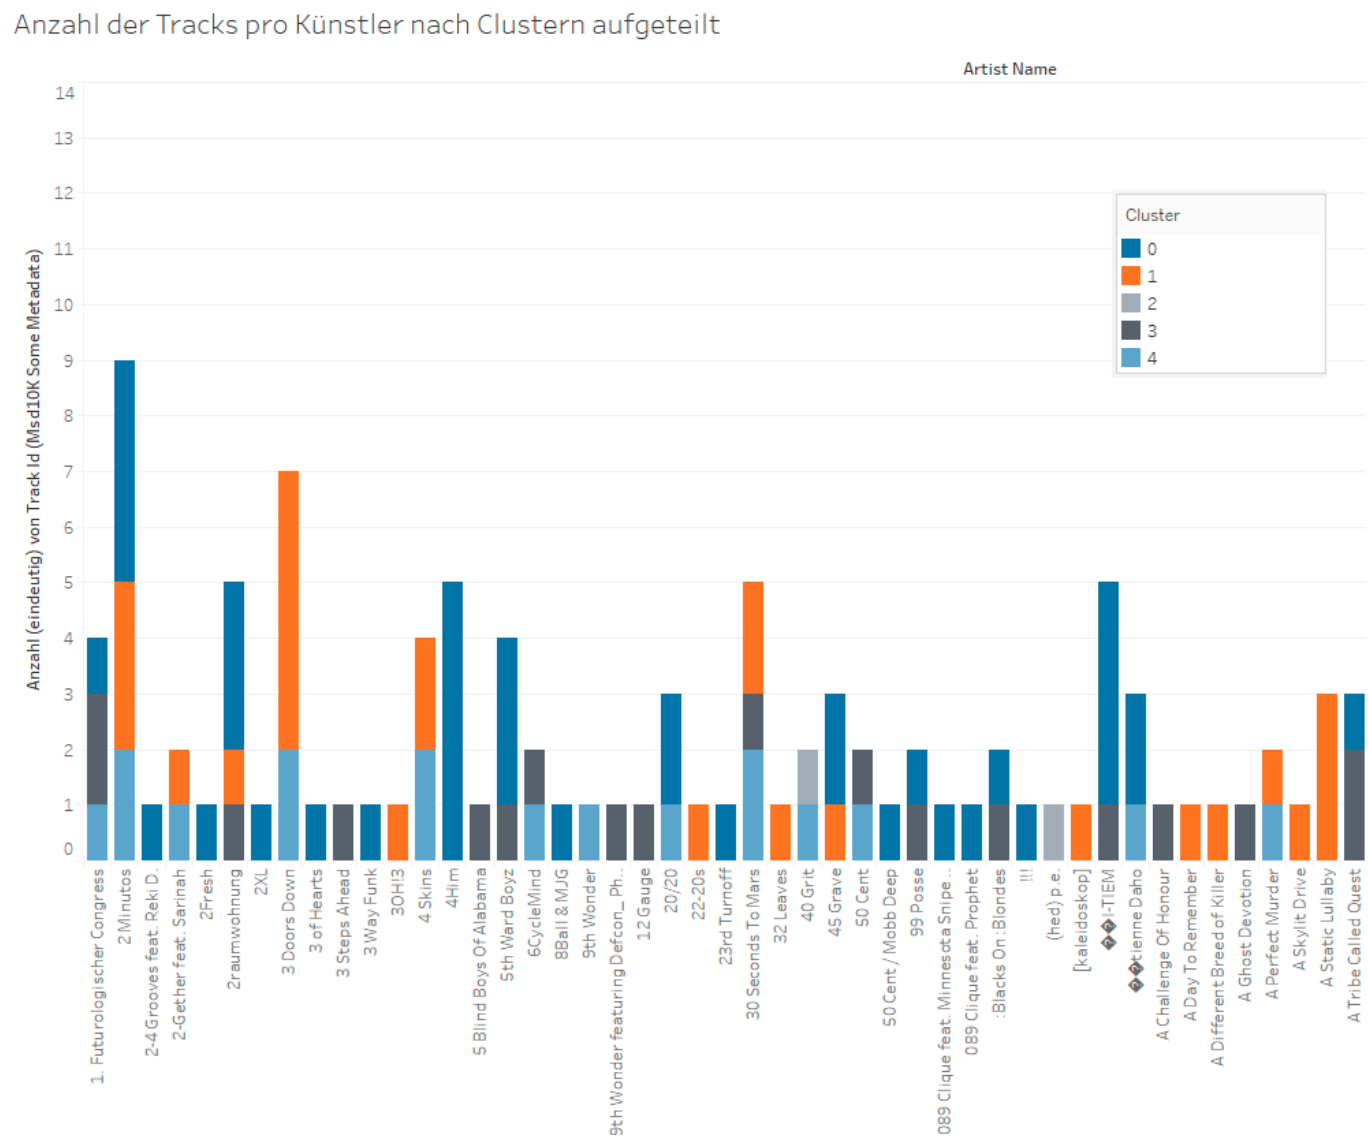

Die Informationen aus Plot 7 sind hier in Form eines Balkendiagramms noch einmal dargestellt. Hier ist die Anzahl der Songs pro Künstler pro Cluster aufsummiert dargestellt. Die Farben entsprechen den folgenden Clustern: (hellblau: 0; grau: 1; hellgrau: 2; orange:3; blau:4)

Plot 9

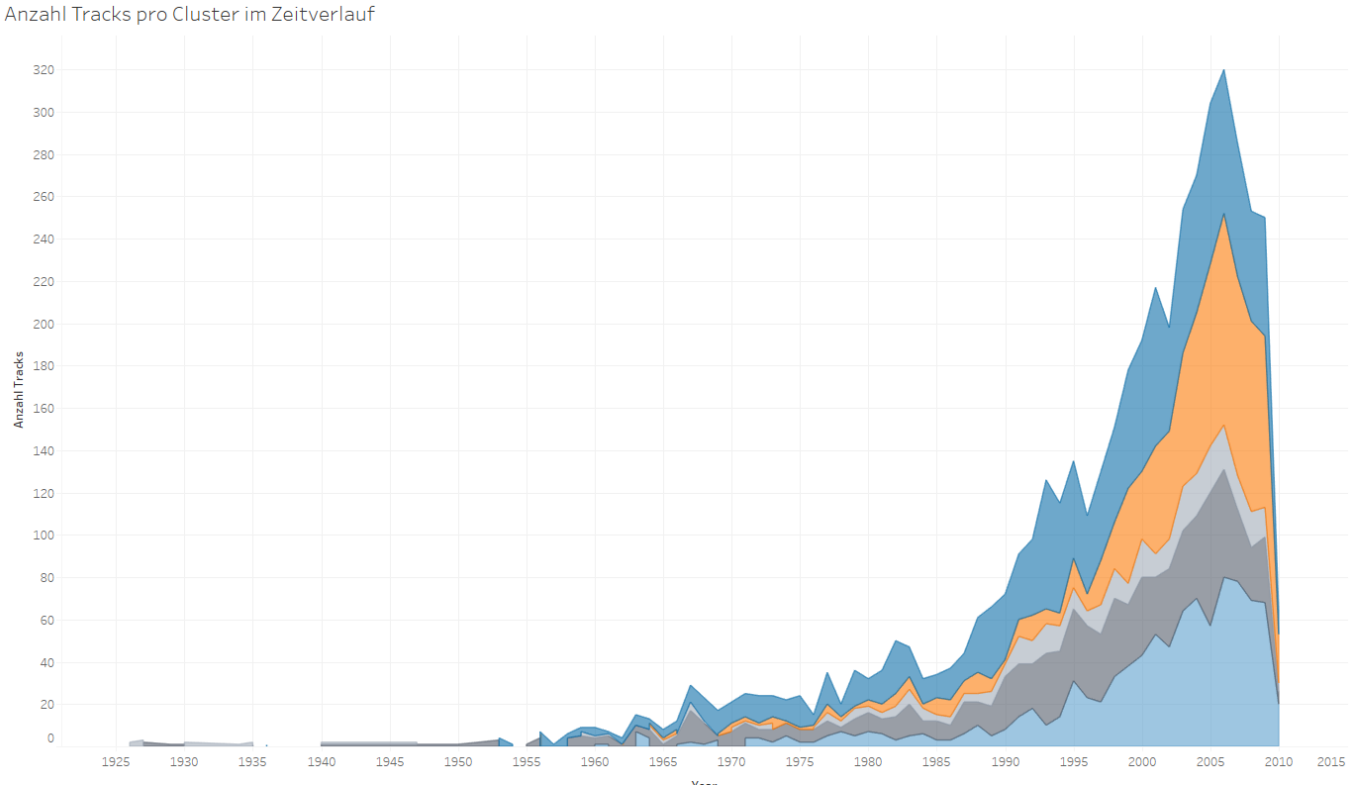

Dieser letzte Plot stellt die Anzahl Songs Pro Cluster im Zeitverlauf dar. Es gilt zu beachten, dass die Flächen nicht hintereinander liegen, sondern die aufsummierte Anzahl wiederspiegeln.

h)

Als Hörproben haben wir verschiedene Songs von einer ausgewählten Künstlerin (**Britney Spears**) angehört, die nach unserer Analyse in verschiedenen Clustern liegen und daher unterschiedliche Lautstärkeprofile haben sollten.

Cluster 0: "My Prerogative" // Mittlere Lautstärke und Tempo

Cluster 1: "Everytime" // Ist ein relativ sanfter Song

Cluster 2: "Someday (I Will Understand)" // Auch eher sanft und ruhig

Cluster 3: keine Songs im Clustervorhanden

Cluster 4: "Oops!...I Did It Again" // Dieser Song ist etwas lauter

Überraschenderweise ist der Song aus Cluster 1 (nach Plot 2 das im durchschnitt lauteste Cluster) relativ leise. Die Songlautstärken aus den anderen Clustern scheinen allerdings der "Clusternorm" zu entsprechen.

Aufgabe 2

Wir übertragen nun die Arbeit aus Aufabe 1 a)-c). Wichtig ist dabei nochmal mittels Elbow Methode zu prüfen, ob eventuell ein andere Anzahl an Clustern notwendig ist.

```
%pyspark
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.clustering import KMeans
from pyspark.ml.clustering import KMeansModel
from pyspark.ml.evaluation import ClusteringEvaluator
from matplotlib import pyplot as plot

#spark.sql("show tables like 'profilevectorpertrack_1m'").show()

df = spark.sql("SELECT * FROM profilevectorpertrack_1m")


assy = VectorAssembler(
    inputCols=["bin1", "bin2", "bin3", "bin4", "bin5", "bin6", "bin7", "bin8", "bin9", "bin10"],
    outputCol="features")

df_vec = assy.transform(df).select("features")
df_vec.show(10)

kmeans = KMeans().setK(2).setSeed(1)
model = kmeans.fit(df_vec)

costvector = []

for i in range(2,16):
    kmeans_loop = KMeans().setK(i).setSeed(1)
    model_loop = kmeans_loop.fit(df_vec)

    centers = model_loop.clusterCenters()
    print("k = " + str(i))
    print("Cluster Centers: ")
    for center in centers:
        print(center)

    # Evaluate clustering.
    costvector.append(model_loop.computeCost(df_vec))

plot.scatter(x=range(2,16) , y=costvector)
```

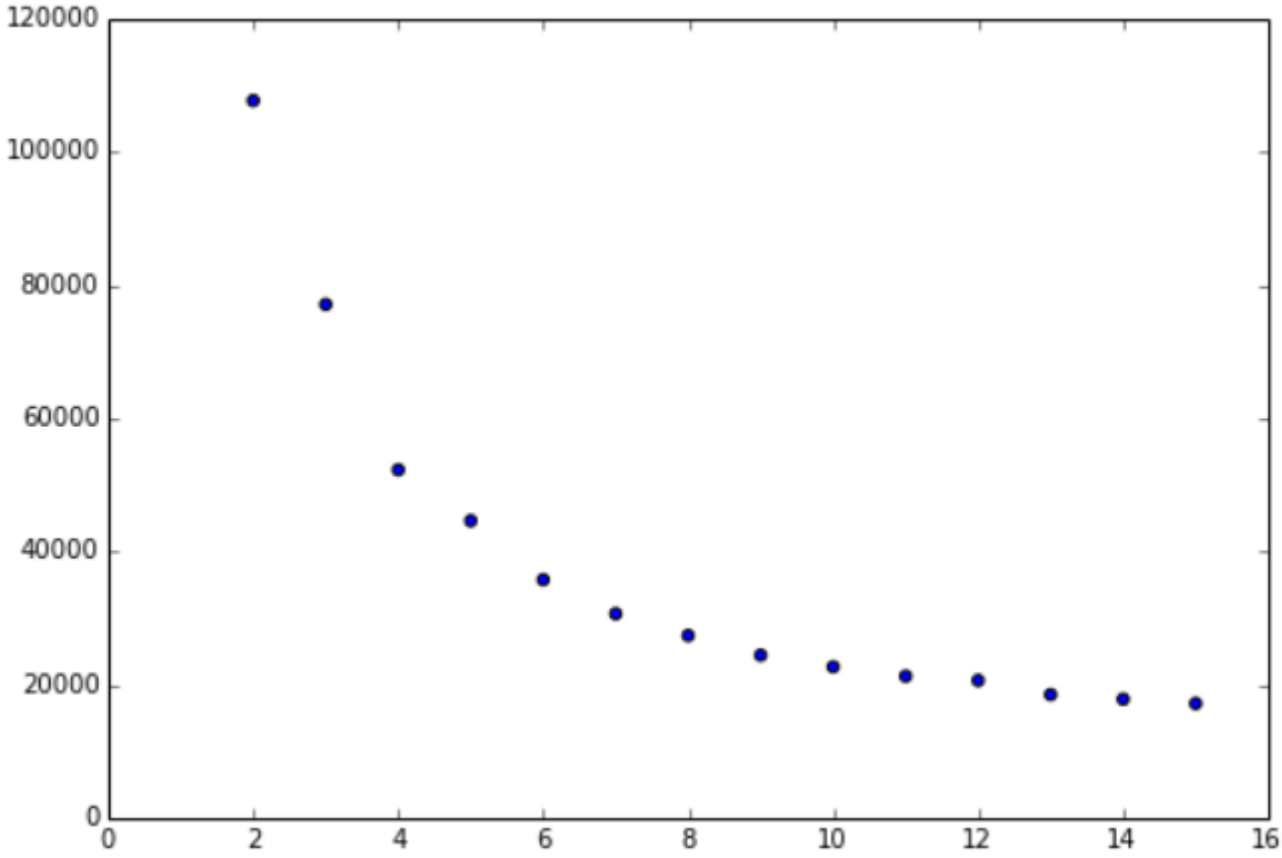

Man sieht einen kleinen Unterschied und hier würde es sich anbieten 6 Cluster zu verwenden.

Die genauen Arbeitsschritte sind im Notebook unter Zeppelin Notebook_GruppeMi6xc dokumentiert.

Unterschiede und Gemeinsamkeiten zwischen 10k und 1M:

Leider traten während der Übertragung der Tableau-Worksheets auf den 1m-Datensatz Probleme mit dem Sparkcluster auf und die Queryzeiten verschoben sich auf über eine Stunde (Abbrechen ging auch nicht mehr, Tableau musste per `kill` geschlossen werden). Es war uns aus diesem Grund nicht möglich, die Unterschiede und Gemeinsamkeiten zwischen den Datensätzen herauszuarbeiten.